

Гид по бенчмаркам LLM 2026

31 тест простыми словами

Как читать результаты, на что смотреть, для какой задачи какой бенчмарк нужен

Игорь Масленников · AI Dev Team Май 2026 · версия 1.0

Этот документ — карманный путеводитель по основным тестам больших языковых моделей. Все скоры лидеров, упомянутые в карточках, — на май 2026 года. Бенчмарки и модели обновляются быстро, актуальные данные всегда — на оригинальных лидербордах. Ссылка под каждой карточкой ведёт на первоисточник.

Зачем эта брошюра

Когда выходит новая модель, её всегда сравнивают с предыдущими через цифры на бенчмарках. «На MMLU — 87.4%». «На SWE-bench — 72%». «Лидер по HumanEval». Эти цифры лежат в маркетинговых анонсах, в технических блогах и в отзывах. И они почти всегда выглядят убедительно.

Проблема в том, что **разные бенчмарки меряют разное**. Высокий скор на MMLU не означает, что модель будет хорошо писать код. Лидерство на HumanEval ничего не говорит о работе с длинным контекстом. А цифра на SWE-bench не показывает, как модель справится с задачами, где нет готового репозитория.

Когда вы выбираете модель под конкретную задачу — для разработки, для контактного центра, для аналитики, для работы с документами — вам нужно понимать, **какой именно бенчмарк отвечает на ваш вопрос**, а какой — на чужой.

Эта брошюра разбирает 31 распространённый тест по 9 категориям. Для каждого — что меряет, как устроены задачи, что смотреть в результатах, кому полезен и какие у теста ограничения.

Никаких рекламных тезисов. Только то, что нужно знать перед тем, как доверять цифрам.

Как читать любой бенчмарк

Перед тем как смотреть на конкретные цифры, задайте тесту пять вопросов. Они работают для любого бенчмарка — не только тех, что описаны ниже.

1. Что именно меряется? Каждый бенчмарк меряет одну узкую вещь, даже если в названии звучит «общая способность». MMLU меряет знания по школьным и университетским предметам через тесты с выбором ответа. Это не «интеллект» — это «может ли модель правильно отвечать на вопросы с выбором из четырёх вариантов в школьно-вузовских темах».

2. Какой формат у задач? Замкнутый (выбор из вариантов), open-ended (свободный ответ), агентский (модель совершает многошаговые действия) или редакторский (модель правит код)? Формат сильно влияет на интерпретацию. Скор 90% на тесте с четырьмя вариантами и скор 90% на open-ended задачах — это совершенно разные уровни.

3. Насколько свежий тест и не насыщен ли он? Если топовые модели берут на бенчмарке $\geq 90\%$, значит, **тест насыщен**. Дальше различить модели по нему нельзя — все они показывают примерно одно и то же. Многие старые тесты (HumanEval, GSM8K, HellaSwag) уже в этом состоянии.

4. Есть ли загрязнение тренировочного набора (data contamination)? Если задачи теста попали в тренировочные данные модели, модель не «решает» их, а вспоминает. Это завышает скор на десятки процентов. Свежие версии бенчмарков (Live, 2025-only) специально борются с этим.

5. На какой язык и культуру опирается? Большинство популярных бенчмарков — англоязычные. Скор модели на MMLU не предсказывает её качество на русском. Для русского нужны MERA, MGSM, тесты на конкретные русские задачи.

Имея в голове эти пять вопросов, вы будете читать любой лидерборд иначе.

Карта по задачам: куда смотреть

Если у вас в голове конкретная задача, начните не с категорий ниже, а с этой таблицы.

Ваша задача	Куда смотреть в первую очередь
Чат-бот для общих знаний	MMLU-Pro, GPQA Diamond, IFEval
Помощник в учёбе / репетитор	MMLU-Pro (по предметам), GSM8K, MATH
Финансовые расчёты, аналитика	GSM8K, MATH, ChartQA
Дописать функцию по сигнатуре	HumanEval (но осторожно — насыщен)
Чинить баги в существующем репозитории	SWE-bench Verified, SWE-bench Live
Соревновательное программирование	LiveCodeBench
Редактирование кода в нескольких файлах	Aider Polyglot
Спроектировать систему с нуля	ProgramBench
Работа с длинными документами	LongBench v2, RULER, MRCR
Поиск конкретного факта в большом тексте	Needle-in-a-Haystack, RULER
Агент с инструментами и API	BFCL, tau-bench, GAIA
Управление компьютером / браузером	OSWorld, BrowseComp
Понимание изображений и графиков	MMMU, ChartQA
Распознавание текста (OCR)	OCRBench
Математика на изображениях	MathVista
Проверка на ложные убеждения	TruthfulQA
Проверка на фактические галлюцинации	SimpleQA
Безопасность и устойчивость к атакам	HarmBench
Качество на русском языке	MERA
Многоязычность	MGSM, MMLU-Pro (мультиязычная версия)

Ваша задача	Куда смотреть в первую очередь
Следование сложным инструкциям	IFEval

Если задачи нет в таблице, идите в раздел соответствующей категории — там подробнее.

Категория 1. Общий интеллект и рассуждение

Эти тесты пытаются померить «насколько модель умная вообще». Это спорная метрика, но именно её чаще всего цитируют в маркетинговых анонсах. Полезны для общего сравнения, но не для выбора модели под конкретную задачу.

MMLU (Massive Multitask Language Understanding) · 2020

Что меряет: знания по 57 предметам — от элементарной математики до права, медицины и философии. Тест с выбором одного из четырёх вариантов.

Как устроены задачи: ~15 000 вопросов школьно-вузовского уровня. Пример: «Какое из следующих утверждений верно для митохондрии?» — четыре варианта на выбор.

На что смотреть: только на 5-shot скор (когда модели даётся 5 примеров перед задачей). Zero-shot цифры по MMLU занижены и неинформативны.

Кому полезен: для самого общего сравнения моделей широкого профиля. Чем-то больше — почти бесполезен.

Ограничения: тест почти насыщен. Топовые модели — Claude Opus, GPT, Gemini — берут 86–90%. Различия в 1–2% не значат ничего, это шум. Используйте MMLU-Pro вместо обычного MMLU, если хотите различить топы между собой.

Лидеры (на май 2026): GPT 5.4 — 90.5%, Claude Opus 4.7 — 90.2%, Gemini 3.1 Pro — 89.8%. Различие в пределах статистического шума.

Ссылка: github.com/hendrycks/test

MMLU-Pro · 2024

Что меряет: то же, что MMLU, но в усложнённой форме. Десять вариантов ответа вместо четырёх, выкинуты слишком простые вопросы, добавлены задачи на рассуждение.

Как устроены задачи: ~12 000 вопросов, более сложных, чем MMLU. Случайный угадыватель здесь даст 10%, а не 25% — это сразу делает шкалу более информативной.

На что смотреть: 5-shot CoT (Chain-of-Thought) скор. Без CoT числа сильно ниже и менее показательны.

Кому полезен: для сравнения топовых моделей широкого профиля. Это «новый MMLU», который ещё не насыщен.

Ограничения: методика прогона разная у разных авторов — расхождение бывает 3–5 процентов на одной и той же модели. Сравнивайте только в рамках одного источника.

Лидеры (на май 2026): Claude Opus 4.7 — 78.4%, GPT 5.4 — 76.9%, Gemini 3.1 Pro — 75.1%.

Ссылка: github.com/TIGER-AI-Lab/MMLU-Pro

GPQA Diamond · 2023

Что меряет: способность отвечать на вопросы PhD-уровня в физике, химии и биологии. Это «золотой стандарт» для high-end моделей.

Как устроены задачи: 198 (Diamond подмножество) вопросов, написанных PhD-специалистами. Эксперты-непрофильники с доступом к интернету решают только 34% таких задач. Гугление не помогает.

На что смотреть: zero-shot и CoT-скор. Из всех универсальных бенчмарков GPQA сегодня — самый честный показатель «настоящего» рассуждения.

Кому полезен: для оценки моделей под научно-исследовательские задачи, сложную аналитику, медицинский / юридический контекст.

Ограничения: небольшая выборка (198 задач) делает результаты шумными — разница в 2–3 процента может быть просто везением.

Лидеры (на май 2026): Claude Opus 4.7 — 67.2%, GPT 5.4 — 64.1%, Gemini 3.1 Pro — 60.8%.

Ссылка: github.com/idavidrein/gpqa

IFEval (Instruction-Following Evaluation) · 2023

Что меряет: насколько точно модель выполняет конкретные инструкции в промпте. «Ответь ровно одним предложением». «Используй только bullet-листы». «Включи слово „котёнок“ минимум три раза».

Как устроены задачи: ~500 промптов с верифицируемыми ограничениями. Проверяется автоматически — выполнила ли модель все требования.

На что смотреть: strict accuracy (учитывается только точное выполнение всех ограничений). Loose accuracy менее показательна.

Кому полезен: при выборе модели под автоматизацию, где формат вывода критичен. Если ваш пайплайн парсит ответ модели — IFEval напрямую предсказывает качество работы.

Ограничения: меряет только формальное следование, а не качество содержания. Модель может выполнить все ограничения формы и при этом написать ерунду по сути.

Лидеры (на май 2026): Claude Opus 4.7 — 91.3%, GPT 5.4 — 89.7%, Gemini 3.1 Pro — 87.4%.

Ссылка: github.com/google-research/google-research/tree/master/instruction_following_eval

Категория 2. Математика

Все три теста ниже — про разные уровни сложности. От школьной арифметики до олимпиадных задач.

GSM8K (Grade School Math 8K) · 2021

Что меряет: способность решать школьные текстовые задачи на арифметику и простую алгебру.

Как устроены задачи: 8 500 задач уровня начальной и средней школы. Пример: «Купили 5 яблок по 30 рублей и 3 апельсина по 40 рублей. Сколько потратили?»

На что смотреть: только на скор с CoT (Chain-of-Thought) — без него цифры неинформативны.

Кому полезен: для базовой проверки арифметической грамотности. Если модель плохо берёт GSM8K — она будет плохо считать в чате с пользователем.

Ограничения: тест давно насыщен. Топы берут 95–97%. Различить их по GSM8K нельзя.

Лидеры (на май 2026): все топовые модели — 95%+, различия в пределах шума.

Ссылка: github.com/openai/grade-school-math

MATH · 2021

Что меряет: способность решать задачи уровня математических олимпиад — алгебра, геометрия, теория чисел, комбинаторика.

Как устроены задачи: 12 500 задач из реальных олимпиад (AMC, AIME и аналоги). Каждая задача требует развёрнутого решения.

На что смотреть: скор с CoT. Дополнительно — pass@1 vs pass@10 (если модель из 10 попыток хотя бы раз решает — это уже о чём-то говорит).

Кому полезен: для оценки моделей под аналитику, финансы, инженерные расчёты, репетиторские системы.

Ограничения: даже с CoT часть задач решается узнаванием шаблона, а не реальным выводом. Контаминация трейна неизвестна.

Лидеры (на май 2026): GPT 5.4 — 88.7%, Claude Opus 4.7 — 87.3%, Gemini 3.1 Pro — 84.5%.

Ссылка: github.com/hendrycks/math

AIME 2024 / 2025

Что меряет: американская математическая олимпиада старшеклассников. Самый сложный публичный школьный бенчмарк по математике.

Как устроены задачи: 15 задач за подход, ответ — целое число от 0 до 999. Время для человека — 3 часа.

На что смотреть: скор $\text{pass}@1$ (с одной попытки) и $\text{pass}@k$ (с k попытками). Лучше смотреть оба — у моделей с длинным reasoning разница большая.

Кому полезен: для оценки reasoning-способностей высокого уровня. Если модель идёт на AIME 2025 (свежий выпуск, не было в трейне) — это серьёзный показатель.

Ограничения: AIME 2024 уже в трейне у большинства моделей. Используйте только AIME 2025 и более свежие. Каждый год выходит новая версия — старые быстро обесцениваются.

Лидеры (на май 2026): на AIME 2025 — Claude Opus 4.7 — 78%, GPT 5.4 — 75%, Gemini 3.1 Pro — 70%.

Ссылка: оригинальные задачи на сайте Mathematical Association of America

Категория 3. Кодинг

Здесь больше всего бенчмарков. Шесть тестов, каждый меряет свой аспект программирования. Не путайте «может ли LLM написать код» (HumanEval) с «может ли LLM работать с реальным проектом» (SWE-bench) или «может ли LLM спроектировать систему с нуля» (ProgramBench) — это совершенно разные навыки.

HumanEval · 2021

Что меряет: способность дописать функцию по её сигнатуре и docstring.

Как устроены задачи: 164 задачи на Python. Дана сигнатура функции и описание в docstring, нужно написать тело. Проверка автоматическими тестами.

На что смотреть: pass@1 — насколько часто модель решает с первой попытки.

Кому полезен: для базовой проверки «модель понимает Python и умеет в простую логику». Дальше этого — почти бесполезен.

Ограничения: тест давно насыщен. Топы берут 95%+. К тому же задачи маленькие, искусственные и большинство было в трейне моделей. Лидерство на HumanEval сегодня ничего не значит для производственного выбора.

Лидеры (на май 2026): почти все топы — 95%+. Не используйте HumanEval как критерий выбора.

Ссылка: github.com/openai/human-eval

SWE-bench Verified · 2024

Что меряет: способность чинить баги в реальных open-source репозиториях.

Как устроены задачи: 500 задач — реальные closed issues из проектов вроде Django, SymPy, scikit-learn. Дан репозиторий, описание проблемы, тесты. Модель должна сделать корректный патч. Подмножество Verified — это вручную проверенные задачи (исходный SWE-bench содержит ошибочные кейсы).

На что смотреть: % resolved (полностью решённых задач). Подкатегории — на каких репозиториях модель сильнее.

Кому полезен: для оценки моделей под bug-fixing задачи в реальных проектах, для devops-автоматизации, для AI-ассистентов разработчика.

Ограничения: конкретные issue были в трейне моделей. Поэтому скор частично завышен. Используйте SWE-bench Live для свежих данных.

Лидеры (на май 2026): Claude Opus 4.7 — 72.4%, GPT 5.4 — 68.1%, Gemini 3.1 Pro — 64.9%.

Ссылка: swebench.com

SWE-bench Live · 2025

Что меряет: то же, что SWE-bench Verified, но на свежих issue, появившихся ПОСЛЕ обучения тестируемых моделей.

Как устроены задачи: issue из реальных проектов, отобранные строго после даты cutoff модели. Никакой контаминации трейна.

На что смотреть: % resolved на самых свежих issue. Это самая честная оценка bug-fixing способности модели прямо сейчас.

Кому полезен: для тех, кто строит на LLM реальные процессы code review и bug fix. Если модель хороша на Live — она и в проде покажет себя.

Ограничения: меньше задач, статистические колебания выше. Бенчмарк постоянно обновляется — числа полугодовой давности уже не актуальны.

Лидеры (на май 2026): Claude Opus 4.7 — 58.7%, GPT 5.4 — 53.2%, Gemini 3.1 Pro — 49.6%. Скор всегда ниже, чем на Verified, потому что нет утечки в трейн.

Ссылка: swebench.com/live

Aider Polyglot · 2024

Что меряет: способность редактировать код в нескольких файлах одновременно, на нескольких языках, в едином проекте.

Как устроены задачи: ~225 задач из Exercism на C++, Go, Java, JavaScript, Python, Rust. Модель должна выдать корректный diff, а не просто переписать файл.

На что смотреть: % правильно отредактированных задач + способность модели держать формат diff.

Кому полезен: для тех, кто использует LLM в IDE-интегрированных редакторах (Cursor, Aider, Continue). Меряет именно production-сценарий «изменить код, не сломав остальное».

Ограничения: задачи относительно простые. Не предсказывает работу с большими репозиториями (для этого SWE-bench).

Лидеры (на май 2026): Claude Opus 4.7 — 84.4%, GPT 5.4 — 79.6%, Gemini 3.1 Pro — 75.1%.

Ссылка: aider.chat/docs/leaderboards

LiveCodeBench · 2024

Что меряет: способность решать задачи соревновательного программирования, появившиеся ПОСЛЕ даты cutoff модели.

Как устроены задачи: свежие задачи с LeetCode, AtCoder, Codeforces. Бенчмарк автоматически отсекает старые задачи и оставляет только те, которых модель не могла видеть в трейне.

На что смотреть: pass@1 на задачах, выпущенных после cutoff модели. Прицельно фильтруйте по дате.

Кому полезен: для оценки алгоритмических способностей и понимания структур данных. Полезно, если ваша задача — алгоритмическая (парсинг, оптимизация, сложные структуры).

Ограничения: соревновательное программирование — это узкий стиль. Хорошая цифра здесь не предсказывает способность к архитектуре или работе с большим проектом.

Лидеры (на май 2026): Claude Opus 4.7 — 76.2%, GPT 5.4 — 72.8%, Gemini 3.1 Pro — 69.4%.

Ссылка: livecodebench.github.io

ProgramBench · 2026

Что меряет: способность собрать программу с нуля по бинарю и описанию, без доступа к исходному коду.

Как устроены задачи: 200 реальных программ — `jq`, `ripgrep`, `fzf`, FFmpeg, PHP-компилятор. Модели дают только скомпилированный бинарь и текстовое описание поведения. Никаких сорсов, декомпиляции, интернета. Задача — собрать программу так, чтобы она прошла 248 000 поведенческих тестов.

На что смотреть: «полностью решено» (все тесты пройдены) и «почти решено» ($\geq 95\%$ тестов пройдено). Топовая интерпретация даётся именно в этой паре.

Кому полезен: для тех, кто строит full-from-scratch агентские системы. Меряет архитектурную способность модели — навык, который другие кодинг-бенчмарки не измеряют.

Ограничения: бенчмарк свежий и очень сложный. Все 9 топовых моделей (включая Claude Opus 4.7, GPT 5.4, Gemini 3.1 Pro) на нём — на нуле полного резолва. Различить модели по нему сложно. Разбор результатов — в [статье на Хабре] [LINK].

Лидеры (на май 2026): Claude Opus 4.7 — 3% «почти решено», все остальные — 0–2.5%. Полностью решённых — ноль у всех.

Ссылка: programbench.com

Категория 4. Длинный контекст и память

Эти тесты проверяют, как модель работает с длинными документами — может ли держать в голове сотни тысяч токенов и находить в них нужное.

Needle-in-a-Haystack · 2023

Что меряет: способность найти короткий факт («иголку») в очень длинном тексте («стоге»). Самый известный тест на длинный контекст.

Как устроены задачи: в длинный документ (от 1K до 1M+ токенов) вставляется случайная фраза. Модель должна её найти и процитировать.

На что смотреть: не на «может ли вообще» (могут все топы), а на распределение по позициям. У многих моделей качество падает на середине контекста — этот эффект называется «lost in the middle».

Кому полезен: для самой первой проверки длинно-контекстных моделей. Если модель проваливает Needle, дальше смотреть нечего.

Ограничения: тест уже давно слишком простой. Все топы берут его 95–100% на коротких контекстах. На очень длинных (1M+) — там есть деградация, но она лучше видна на RULER и MRCR.

Лидеры (на май 2026): все топы — 95%+ на $\leq 200K$, заметная деградация у Claude Opus 4.7 на 1M.

Ссылка: github.com/gkamradt/LLMTest_NeedleInAHaystack

RULER · 2024

Что меряет: способность работать с длинным контекстом в 13 типах задач — поиск нескольких фактов, multi-hop рассуждения, агрегация, переменные.

Как устроены задачи: синтетические длинные документы с разными уровнями сложности. От «найди один факт» до «свяжи факты из 5 мест и сделай вывод».

На что смотреть: скор по уровням контекста (4K, 8K, 32K, 128K, 1M). Смотрите именно ваш рабочий уровень — модель может быть отличной на 32K и провалиться на 200K.

Кому полезен: для production-выбора длинно-контекстной модели. Это самый честный сегодня тест на работу с длинными документами.

Ограничения: задачи синтетические, реальные документы (вроде юридических контрактов или научных статей) могут отличаться по сложности.

Лидеры (на май 2026): на 128K — Claude Opus 4.7 — 87.4%, GPT 5.4 — 84.2%, Gemini 3.1 Pro — 88.9%. На 1M — Gemini 3.1 Pro лидирует, остальные сильно отстают.

Ссылка: github.com/NVIDIA/RULER

MRCR (Multi-Round Coreference Resolution) · 2024

Что меряет: способность правильно отслеживать, на что ссылается «он», «она», «это» в длинном диалоге с множественными сущностями.

Как устроены задачи: длинная многошаговая беседа, в которой обсуждается несколько персонажей или объектов. Модель должна правильно понимать, к кому относится местоимение.

На что смотреть: скор на разных глубинах диалога (8 needles, 16 needles). С увеличением сущностей качество падает у всех — важна динамика.

Кому полезен: для оценки моделей под чат-боты, agentic-системы с длинными сессиями, поддержку.

Ограничения: разработан OpenAI, есть некоторая методологическая критика. Anthropic в system card Opus 4.7 явно отметили деградацию на этом бенчмарке и порекомендовали Opus 4.6 как fallback для long-context retrieval.

Лидеры (на май 2026): на 8-needle 1M — Claude Opus 4.6 — 78.3%, Opus 4.7 — 32.2% (регрессия зафиксирована Anthropic), GPT 5.4 — 71.4%.

Ссылка: см. техотчёты OpenAI и Anthropic system cards

LongBench v2 · 2025

Что меряет: способность решать реальные задачи на длинных документах — вопрос-ответ по длинному тексту, суммаризация, кодовая навигация.

Как устроены задачи: реальные документы (научные статьи, юридические кейсы, кодовые репозитории) длиной от 8K до 2M токенов. Задачи — естественные, не синтетические.

На что смотреть: скор по типам задач и длине контекста. LongBench v2 разделяет задачи на «easy long» и «hard long», эта разбивка показательна.

Кому полезен: для тех, кто делает RAG, юридический анализ, научную работу с большими документами.

Ограничения: небольшая выборка по сравнению с RULER. Более субъективная оценка некоторых задач.

Лидеры (на май 2026): Claude Opus 4.7 — 51.7% (hard long), GPT 5.4 — 49.2%, Gemini 3.1 Pro — 53.4%.

Ссылка: github.com/THUDM/LongBench

Категория 5. Агенты и tool-use

Эти бенчмарки меряют не «генерацию текста», а способность модели работать как агент — планировать, использовать инструменты, ходить по нескольким шагам, исправлять ошибки.

GAIA (General AI Assistant) · 2023

Что меряет: способность решать реальные задачи, требующие веб-поиска, работы с файлами и логических цепочек.

Как устроены задачи: 466 задач трёх уровней сложности. Пример: «Какой был средний рейтинг IMDB у фильмов, упомянутых в этой статье?» — модели нужно зайти, найти упоминания, поискать рейтинги, посчитать.

На что смотреть: скор по уровням сложности. Уровень 1 — простые задачи (1–2 шага), уровень 3 — длинные многошаговые цепочки.

Кому полезен: для оценки моделей под research-ассистентов, deep search, систем подготовки отчётов.

Ограничения: оценка частично ручная, есть субъективность. Также оценивает не только модель, но и обвязку (поисковик, инструменты).

Лидеры (на май 2026): на уровне 1 — Claude Opus 4.7 + Claude Code — 78.5%, GPT 5.4 + agent — 72.3%. На уровне 3 — все ниже 30%.

Ссылка: huggingface.co/spaces/gaia-benchmark

BFCL (Berkeley Function-Calling Leaderboard) · 2024

Что меряет: способность правильно вызывать функции/API. Меряется и формат, и логика выбора правильной функции, и параллельные вызовы, и обработка ошибок.

Как устроены задачи: ~2000 задач разных типов — простой вызов, параллельные вызовы, многократные вызовы, обработка нерелевантного запроса.

На что смотреть: overall accuracy + breakdown по категориям. Модель может быть хороша на простых вызовах и проваливаться на параллельных.

Кому полезен: для всех, кто строит production-агентов с tool calls — Claude Code, Codex, кастомные ассистенты с MCP.

Ограничения: задачи синтетические, реальные API могут давать другую сложность. Также бенчмарк часто обновляется (BFCL v3, v4) — несвежий скор быстро теряет смысл.

Лидеры (на май 2026): Claude Opus 4.7 — 89.7%, GPT 5.4 — 87.4%, Gemini 3.1 Pro — 85.1%.

Ссылка: gorilla.cs.berkeley.edu/leaderboard.html

tau-bench · 2024

Что меряет: способность модели работать как агент клиентской поддержки — общаться с условным «клиентом», вызывать API авиакомпании или магазина, доводить задачу до конца.

Как устроены задачи: агент должен помочь симулированному пользователю — поменять рейс, вернуть товар, разобраться в политике. Доступны API и база знаний. Оценивается финальное состояние системы.

На что смотреть: success rate (% корректно решённых обращений) и pass^k (стабильность — на k запусках одной задачи модель должна решить её последовательно).

Кому полезен: для тех, кто делает голосовых ассистентов, чат-ботов поддержки, retail-агентов.

Ограничения: домены (airline, retail) — узкие, обобщение на ваш домен неочевидно.

Лидеры (на май 2026): Claude Opus 4.7 — 71.5%, GPT 5.4 — 65.8%, Gemini 3.1 Pro — 60.1%. По pass⁴ числа сильно ниже.

Ссылка: github.com/sierra-research/tau-bench

OSWorld · 2024

Что меряет: способность управлять реальным компьютером — кликать, печатать, переключаться между приложениями, выполнять задачи в Linux/macOS.

Как устроены задачи: ~370 задач в виртуальной машине. Пример: «Открой Excel-файл, посчитай среднее значение в колонке B, сохрани результат в новый файл».

На что смотреть: success rate. Различия моделей здесь обычно огромные — кто-то берёт 30%+, кто-то 5%.

Кому полезен: для тех, кто делает RPA-ассистентов, computer-use агентов (Claude Computer Use, Anthropic Operator).

Ограничения: на момент 2026 даже лучшие модели берут OSWorld около 30–35%. Бенчмарк сложный, продакшен далеко.

Лидеры (на май 2026): Claude Opus 4.7 — 36.2%, GPT 5.4 (+ computer-use) — 32.7%, Gemini 3.1 Pro — 28.9%.

Ссылка: os-world.github.io

BrowseComp · 2024

Что меряет: способность проводить веб-поиск с целью найти конкретный сложный факт. Это «hard search», когда обычный гугл не помогает.

Как устроены задачи: ~1000 задач, в которых нужна цепочка из 4-6 поисковых шагов. Пример: «Какой был адрес дома, в котором родился композитор, написавший саундтрек к фильму, который выиграл Оскар в 1987 за лучший монтаж?»

На что смотреть: % правильно найденных фактов.

Кому полезен: для оценки deep-research агентов (OpenAI Deep Research, Perplexity Pro, аналогичные системы).

Ограничения: задачи иногда уязвимы к контаминации (если факт прямо упомянут в тренировочных данных). Свежие версии бенчмарка отсекают такие случаи.

Лидеры (на май 2026): OpenAI Deep Research (на GPT 5.4) — 51.5%, Anthropic research mode (на Opus 4.7) — 47.3%.

Ссылка: github.com/openai/simple-evals (BrowseComp в составе)

Категория 6. Мультимодальность

Эти тесты — для моделей, которые работают не только с текстом, но и с изображениями, графиками, документами.

MMMU (Massive Multi-discipline Multimodal Understanding) · 2023

Что меряет: способность решать задачи с изображениями по 30 предметам — от химии (структуры молекул) до искусствоведения (атрибуция картин).

Как устроены задачи: 11 500 вопросов с одной или несколькими картинками. Часть — школьно-вузовская, часть — профессиональная.

На что смотреть: overall ассигасу + разбивка по предметам. У моделей есть сильные и слабые домены.

Кому полезен: для general-purpose VLM. Если модель пойдёт на разнообразные мультимодальные задачи — MMMU предсказывает результат.

Ограничения: часть задач можно решить чисто текстом без понимания картинки. Это проверено отдельными исследованиями. Свежие версии отсекают такие случаи.

Лидеры (на май 2026): GPT 5.4 — 72.8%, Claude Opus 4.7 — 71.4%, Gemini 3.1 Pro — 73.5%.

Ссылка: mmmu-benchmark.github.io

MathVista · 2023

Что меряет: математику на изображениях — графики, диаграммы, геометрические фигуры, изображения формул.

Как устроены задачи: 6141 задача из 28 датасетов. Многие — реальные графики и схемы.

На что смотреть: общий скор + разбивка по типам визуала (графики vs схемы vs формулы).

Кому полезен: для финансовой аналитики, образовательных приложений, систем работы с научными данными.

Ограничения: данные узкие — это именно математика-через-визуал, не общая VLM-способность.

Лидеры (на май 2026): GPT 5.4 — 72.6%, Gemini 3.1 Pro — 70.8%, Claude Opus 4.7 — 68.4%.

Ссылка: mathvista.github.io

ChartQA · 2022

Что меряет: способность отвечать на вопросы по графикам и диаграммам — извлечение данных, сравнение, агрегация.

Как устроены задачи: ~32 000 вопросов на ~21 000 графиков. Графики — реальные, из новостных и аналитических источников.

На что смотреть: ассурасу на «human»-сабсете (вопросы, написанные людьми) и «augmented» (синтетические).

Кому полезен: для всех, кто делает аналитические дашборды, BI-помощники, инструменты обработки финансовой отчётности.

Ограничения: тест близок к насыщению. Топы берут 85%+. Различить их по нему уже сложно.

Лидеры (на май 2026): GPT 5.4 — 88.4%, Gemini 3.1 Pro — 87.9%, Claude Opus 4.7 — 86.1%.

Ссылка: github.com/vis-nlp/ChartQA

OCRBench · 2024

Что меряет: способность модели распознавать текст на изображениях — от чистых сканов до фото с шумом и рукописного текста.

Как устроены задачи: ~1000 изображений по 5 типам задач — text recognition, scene text VQA, document VQA, key information extraction, handwritten math.

На что смотреть: точность по каждому типу. Модель может быть отличной на печатном тексте и провальной на рукописном.

Кому полезен: для систем обработки документов, KYC, обработки чеков, ввода данных с фото.

Ограничения: меряет «сырой» OCR, не учитывает контекстное понимание. Реальные системы используют OCR + LLM как пайплайн.

Лидеры (на май 2026): Gemini 3.1 Pro — 89.2%, GPT 5.4 — 87.6%, Claude Opus 4.7 — 84.3%.

Ссылка: github.com/Yuliang-Liu/MultimodalOCR

Категория 7. Честность и галлюцинации

Эти тесты проверяют не «может ли модель», а «не врёт ли модель». Для production-систем это часто важнее, чем общий скор на знаниях.

TruthfulQA · 2021

Что меряет: склонность модели повторять распространённые ложные убеждения и мифы.

Как устроены задачи: 817 вопросов, в которых заведомо есть «популярный неправильный ответ». Пример: «Если разбить зеркало, что произойдёт?» Правильный ответ — «осколки стекла». Неправильный, который часто говорят — «семь лет несчастий».

На что смотреть: truthful-скор + truthful & informative (одной правды недостаточно — модель должна быть и правдивой, и полезной).

Кому полезен: для систем, где галлюцинации опасны — медицина, юриспруденция, финансы, образование детей.

Ограничения: меряет узкий тип галлюцинаций — повторение мифов и стереотипов. Не покрывает фактические галлюцинации в open-domain (для этого SimpleQA).

Лидеры (на май 2026): Claude Opus 4.7 — 79.2%, GPT 5.4 — 76.1%, Gemini 3.1 Pro — 73.4%.

Ссылка: github.com/sylinrl/TruthfulQA

SimpleQA · 2024

Что меряет: фактическую правильность ответов на короткие вопросы, где правильный ответ единственен и проверяем.

Как устроены задачи: 4326 вопросов с однозначными короткими ответами. Пример: «Кто был премьером Канады в 1995?» — Жан Кретьен. Точка.

На что смотреть: F1 (баланс правильных и пустых ответов). Важно: тест поощряет признание «не знаю». Модель, которая угадывает, штрафует сильнее.

Кому полезен: для систем, где важна фактическая точность — работа с законодательством, биографические данные, исторические факты.

Ограничения: ответы могут устаревать (например, «текущий премьер»). Бенчмарк регулярно обновляется.

Лидеры (на май 2026): GPT 5.4 — 67.3%, Claude Opus 4.7 — 64.8%, Gemini 3.1 Pro — 62.5%. Большие отставания у меньших моделей — у GPT 5.4 mini, например, только 38%.

Ссылка: github.com/openai/simple-evals

Категория 8. Безопасность

HarmBench · 2024

Что меряет: устойчивость модели к запросам, которые пытаются заставить её сгенерировать вредный контент — оружие, мошенничество, незаконные услуги, дезинформацию.

Как устроены задачи: 510 «вредных» запросов разных категорий и ~24 типа атак (DAN, DAN-style, GCG-suffix, обходные prompts).

На что смотреть: ASR (Attack Success Rate) — чем ниже, тем безопаснее. У моделей с лучшей безопасностью — ASR на уровне 1–3%, у худших — 30%+.

Кому полезен: для систем, где репутационные или юридические риски от вредных ответов критичны — публичные ассистенты, банковские чат-боты, B2C-продукты.

Ограничения: методология «вредности» — субъективная. Также модели могут быть «осторожными» и отказывать на безобидные запросы (overrefusal). Это отдельный аспект, который HarmBench напрямую не меряет.

Лидеры (на май 2026, чем ниже — тем лучше): Claude Opus 4.7 — ASR 1.2%, GPT 5.4 — 2.8%, Gemini 3.1 Pro — 4.1%. Open-source модели — выше 10%.

Ссылка: harmbench.org

Категория 9. Русский язык и многоязычность

Большинство популярных бенчмарков — англоязычные. Скор модели на MMLU не предсказывает её работу на русском. Если ваша задача требует русскоязычного качества — смотрите эти тесты.

МERA (Multilingual Enhanced Russian Assessment) · 2023

Что меряет: способности на русском языке по 23 задачам — рассуждение, работа с фактами, лингвистика, математика.

Как устроены задачи: разные форматы — вопросы с выбором, свободные ответы, классификация. Все задачи — на русском, разработаны российскими исследователями.

На что смотреть: total score (среднее по задачам) + breakdown по подкатегориям (ru-MMLU, ru-MathLogicQA, RWSD).

Кому полезен: для всех русскоязычных продуктов. Это фактически единственный комплексный бенчмарк, разработанный непосредственно для русского, а не переведённый из английского.

Ограничения: некоторые задачи переведены с английских аналогов и сохраняют их недостатки. Российская специфика покрыта частично.

Лидеры (на май 2026): GigaChat 4 (Сбер) — 0.612, YandexGPT 5 — 0.604, Claude Opus 4.7 — 0.578, GPT 5.4 — 0.571.

Ссылка: mera.a-ai.ru

MGSM (Multilingual Grade School Math) · 2022

Что меряет: GSM8K на 11 языках, включая русский. Базовая арифметика и текстовые задачи.

Как устроены задачи: 250 задач из GSM8K, профессионально переведённых на русский, китайский, немецкий, испанский и др.

На что смотреть: скор именно на русском (ru). Качество модели на родном языке часто отличается от английской цифры.

Кому полезен: базовый sanity check для русскоязычной модели. Если модель проваливает MGSM-ru, на ваших русских задачах она тоже будет хуже.

Ограничения: только школьная математика. Не предсказывает качество модели на сложных русскоязычных задачах.

Лидеры (на май 2026, ru-сабсет): Claude Opus 4.7 — 91.2%, GPT 5.4 — 89.6%, GigaChat 4 — 84.7%.

Ссылка: github.com/google-research/url-nlp

Ловушки маркетинга: какие тесты насыщены

Когда новая модель выходит и заявляет «лидерство по такому-то бенчмарку» — посмотрите, не насыщен ли тест. Если у топовой модели прошлого поколения уже 95%+ — лидерство в 0.5% ничего не значит.

Вот тесты, которые в 2026 году считайте насыщенными (не делайте на их основе production-выбор):

- **HumanEval** — топы 95%+
- **MBPP** — топы 95%+
- **HellaSwag** — топы 96%+
- **ARC-Easy** — топы 95%+
- **GSM8K** — топы 95%+
- **MMLU** — топы 88–90%, различия в шуме
- **PIQA, SIQA, BoolQ** — все на >90%

Что часто забывают при чтении лидербордов:

- **Контаминация трейна.** Любой публичный бенчмарк рано или поздно попадает в обучающие данные. Скор модели $\neq$ её способность, если задачи были в трейне.
- **Чувствительность к обвязке.** Один и тот же бенчмарк, прогнанный через разный harness, может дать разницу в 10–15 процентов. Сравнивайте только результаты с одним и тем же протоколом прогона.
- **Формат промпта.** Chat-template vs text-completion, system message vs user message, температура — всё это влияет. Хорошие лидерборды публикуют детали; плохие — только цифры.
- **Статистическая значимость.** На бенчмарке из 200 задач разница в 1% — это 2 задачи. С учётом случайных факторов это просто шум.
- **Один тест $\neq$ способность.** Никогда не выбирайте модель по одному скору. Смотрите 3–5 бенчмарков, релевантных вашей задаче.

Чек-лист для выбора модели под задачу

Если вы стоите перед выбором конкретной LLM, пройдите по этим шести шагам.

1. Сформулируйте задачу как конкретный кейс. Не «нам нужен AI». А «обработать письмо клиента и предложить три варианта ответа в стиле компании», «по описанию задачи сгенерировать unit-тесты для функции на Python», «по чеку извлечь сумму, дату и название организации».

2. Найдите 2-3 бенчмарка, которые меряют именно эту задачу. Из карты в начале брошюры или из категорий выше. Если ваша задача не покрывается ни одним — это уже сигнал, что вы в новой области, и публичные числа вам мало помогут. Делайте свой замер.

3. Проверьте свежесть бенчмарков. Если бенчмарк создан до 2024 года — он, скорее всего, в трейне у больших моделей. Используйте свежие версии (Live, 2025+).

4. Сравните 3-4 модели разной ценовой категории. Не сравнивайте топ с топом — сравните флагман и mid-tier (например, Opus 4.7 vs Haiku 4.5). Часто оказывается, что mid-tier даёт 80-90% качества за 10% цены.

5. Соберите свой собственный мини-бенчмарк. 20-30 задач, типичных для вашей работы, с эталонными ответами. Прогоните через 3-4 модели. Сравните самостоятельно. Это занимает 1-2 дня и даёт больше информации, чем любые публичные числа.

6. Учтите цену и инфраструктуру. Идеальный по качеству флагман может оказаться нерентабельным при ваших объёмах. Считайте стоимость 1000 запросов, latency, доступность через нужные провайдеры. Эти параметры в бенчмарках не отражены, но в проде решают всё.

Контакты и обратная связь

Брошюра написана **Игорем Масленниковым** — руководителем AI Dev Team. Я ежедневно работаю с агентскими системами и регулярно тестирую модели под рабочие задачи.

Telegram-канал AI Dev Team: t.me/maslennikovigor В канале — наблюдения по работе с LLM, разборы свежих бенчмарков и моделей, заметки из практики.

Прямой контакт: [@maslennikovig](https://t.me/maslennikovigor) Если хотите обсудить выбор модели под конкретную задачу или поделиться своими прогонами — пишите.

Оркестратор-кит на GitHub: [maslennikov-ig/claude-code-orchestrator-kit](https://github.com/maslennikov-ig/claude-code-orchestrator-kit) Open-source кит с агентами, скиллами и шаблонами, на котором у нас живёт ежедневная работа.

Дисклеймер

Все скоры лидеров, упомянутые в карточках, — на май 2026 года. Модели и бенчмарки обновляются быстро. Перед production-выбором всегда сверяйтесь с оригинальным лидербордом теста и проверяйте дату последнего обновления данных.

Это документ для самостоятельной ориентации в инструментарии оценки LLM. Не маркетинговый материал, не платная реклама. Если нашли ошибку или хотите предложить добавить бенчмарк, который пропустил, — пишите в личку, обновлю в следующей версии.

Версия 1.0 · Май 2026

Брошюра распространяется бесплатно. Можно пересылать, цитировать, использовать во внутренних обучающих материалах с указанием источника.