

• Maslennikov · AI Dev Team

LEAD-MAGNET · V1.0 · МАЙ 2026

Карта решений по Claude и Claude Code

Что использовать когда — матрица из практики. Subagents с Agent View, Skills с Plugin Marketplace, Cowork, Opus 4.7 с `/effort` и `/fast`, Agent Teams: когда брать, когда не брать, типичные ошибки и комбо-приёмы.

ВЕРСИЯ	ДАТА	АВТОР	КАНАЛ
1.0	Май 2026	Игорь Масленников	@maslennikovigor

Зачем эта шпаргалка

Сначала — честно: subagents, skills и MCP-протокол существуют у Anthropic уже больше года. Делать вид, что это новинки квартала, — нечестно. А вот за период февраль-май 2026 реально вышло другое: **Agent Teams** (5 февраля), **Claude Cowork в GA** (9 апреля), **Opus 4.7 с командами `/effort` и `/fast`** (поздний апрель), **Plugin Marketplace** с auto-update, **Agent View** (12 мая). Плюс отдельная история про мартовский token bug v2.1.88, который выжег лимиты целой команде. Каждая фича решает свою задачу, и применить их «все сразу» — гарантированный способ съесть бюджет токенов и не получить пользы.

Эта одностраничная карта отвечает на самый частый вопрос: «**вот моя задача — какой из инструментов Claude её решает лучше всего?**»

Карта построена так, чтобы можно было распечатать и держать рядом с рабочим столом. Дальше — шесть карточек по каждому инструменту: **что брать, что не брать, типичные ошибки**. Плюс отдельный блок про мартовский bug (анти-новинка квартала) и комбо-приёмы, которые реально работают.

Главная матрица: задача → инструмент

что нужно сделать	лучший инструмент	почему
Собрать информацию по большой кодовой базе	Параллельные subagents (3+ Explore) + Agent View	Контекст основной сессии остаётся чистым
Аудит безопасности + зависимости + dead code	Параллельные спес-агенты	15 минут параллельно вместо вечера последовательно
Сложная задача с глубоким рассуждением	Opus 4.7 + <code>/effort=extra-high</code>	Часто лучше Agent Teams и в 3–7 раз дешевле
Координация большой задачи через peer-to-peer	Agent Teams (experimental, ×3–7 токенов)	Только когда задача масштаба «компилятор на 100K строк»
Найти готовый skill под задачу	Plugin Marketplace через <code>/skills</code> или <code>/plugin</code>	2810 skills и 425 plugins в community marketplaces
Повторяющаяся процедура (релиз, ревью, статья)	Skill в <code>SKILL.md</code>	Подгружается только когда нужна
Бытовая рутина: папки, чеки, sync файлов	Claude Cowork	Десктоп + файловая система + connectors
Финансовая аналитика, payroll, bookkeeping	Cowork + Claude for Small Business	15 готовых skills + connectors к QuickBooks/Stripe
Длинная сессия с агрессивным рассуждением	Opus 4.7 + ручной <code>/compact</code> до 200K	1M контекст — маркетинг, реально полезных ~300K
Быстрые итерации по варианту решения	Opus 4.7 в режиме <code>/fast</code>	Тот же Opus, ответ за 15–20 секунд
Работа с актуальной документацией библиотек	MCP-сервер <code>context7</code>	Свежий API в момент работы

ЧТО НУЖНО СДЕЛАТЬ	ЛУЧШИЙ ИНСТРУМЕНТ	ПОЧЕМУ
UI-тестирование и скриншоты живых страниц	MCP-сервер <code>playwright</code>	Один промт — есть готовый снимок
Поиск компонентов и быстрая интеграция UI	MCP-сервер <code>shadcn</code>	Каталог с поиском и установкой одной командой
Многошаговое рассуждение по сложной задаче	MCP-сервер <code>sequential-thinking</code>	Меньше прыжков логики
Обычный диалог, brainstorming, объяснение	Стандартный чат, без всего	Не перегружать там, где можно проще

Параллельные subagents и Agent View

Карточка 1 · Subagents + Agent View

ГОД+ · AGENT VIEW С МАЯ 2026

Запуск нескольких специализированных Claude-агентов одной командой. Каждый получает свой контекст, свой `subagent_type`, свой набор инструментов. Можно ставить в фон через `run_in_background: true`. С 12 мая 2026 появился **Agent View** — централизованный UI для управления всеми параллельными сессиями и background-задачами.

КОГДА БРАТЬ

- Сбор информации по большому коду (Explore-агенты)
- Параллельный аудит — security, dependencies, dead code
- Подготовка релиза — несколько независимых проверок
- Сравнительное исследование альтернатив
- Длинные задачи, где основной чат не должен ждать

КОГДА НЕ БРАТЬ

- Задача не декомпозируется на независимые куски
- Результаты придётся мерджить — лучше последовательно
- Простая правка одного файла — overhead больше пользы

ТИПИЧНЫЕ ОШИБКИ

- Запустить 5 агентов на сложную задачу с пересекающимися областями — половина дублируется
- Забыть передать каждому агенту нужный контекст — отчёты приходят полупустые
- Использовать для задач, где ценны промежуточные шаги — теряется наблюдаемость

Карточка 2 · Skills + Plugin Marketplace

SKILLS С ОКТЯБРЯ 2025 · MARKETPLACE РАСТЁТ

Маленькие модульные `SKILL.md`-файлы с инструкциями для конкретной процедуры. Claude Code находит и подгружает их по триггеру. Альтернатива большому монолитному `CLAUDE.md`. За квартал вокруг skills вырос полноценный **Plugin Marketplace**, и главная его ценность — **автоматическое обновление**: поставил один раз, дальше Claude Code сам подтягивает свежие версии при запуске. Плюс `--plugin-url` и `--plugin-dir` с .zip, промпты `/skills` и `/plugin` с type-to-filter. В community-каталогах к маю — около 2810 skills и 425 plugins.

КОГДА БРАТЬ

- Задача повторяема по смыслу, но не по конкретным шагам (статья, релиз-чек-лист)
- Процедуры, которые иначе занимали бы место в `CLAUDE.md` без постоянной нужды
- Действия, которые сложно описать алгоритмически, но легко — пошагово
- Когда хочется делиться рецептами с командой

КОГДА НЕ БРАТЬ

- Задача решается простым скриптом — пиши скрипт
- Одноразовая операция — оверкилл
- Когда нужно строгое детерминированное поведение — skill не гарантирует

ТИПИЧНЫЕ ОШИБКИ

- Запихнуть в один skill пять разных задач — он перестает срабатывать правильно
- Не указать триггер в описании — Claude не подгрузит вовремя
- Делать skill про «какая у тебя профессия» вместо «как её выполнять» — это работа для agent

ПАМЯТКА ПРО РАЗГРАНИЧЕНИЕ

Agent = какая у тебя профессия (writer, backend-dev, security-auditor)

Skill = как эту профессию выполнять (структурировать статью, накатить миграцию)

Карточка 3 · Claude Cowork

GA C 9 АПРЕЛЯ 2026

Desktop-агент Anthropic для macOS и Windows. Работает с файловой системой и подключёнными сервисами (Google Drive, Gmail, Slack, DocuSign, QuickBooks, Stripe и др.). Перед каждой операцией показывает план — можно одобрить, поправить, отменить.

КОГДА БРАТЬ

- Бардак в Downloads / на рабочем столе — разбор по категориям
- Папка скриншотов чеков → табличка с суммами
- Синхронизация двух папок между устройствами
- Сборка отчётов из писем за период
- Малый бизнес: payroll, bookkeeping (через Claude for Small Business)

КОГДА НЕ БРАТЬ

- Серьёзная аналитическая работа с ценой ошибки
- Задачи, где нужен явный код и git-история
- Сценарии, где требуется обширное многошаговое рассуждение

ТИПИЧНЫЕ ОШИБКИ

- Дать доступ ко всей файловой системе сразу — давай по папкам
- Принять план не глядя — иногда Cowork предлагает странное
- Использовать вместо Claude Code для разработки — это два разных продукта

Opus 4.7 + /effort + /fast

Карточка 4 · Opus 4.7 + /effort + /fast

МОДЕЛЬ + 2 КОМАНДЫ УПРАВЛЕНИЯ

Свежая модель Anthropic (поздний апрель 2026) с нативным 1М контекстом. Две команды управления поведением: `/effort` задаёт уровень рассуждения (low / medium / high / extra-high / xhigh), `/fast` — ускоренная инференсная конфигурация того же Opus, ответ в 2–2.5 раза быстрее. Бенчмарки `/fast` и стандарта одинаковые (SWE-bench Verified 87.6%). Но `/fast` дороже в 6 раз: \$30/\$150 за 1M input/output против \$5/\$25 у стандартного Opus 4.7.

КОГДА БРАТЬ

- `/effort=extra-high` — рабочая модель для сложных задач (архитектура, рефакторинг, многошаговая отладка)
- `/fast` — интерактивные задачи, где каждая секунда задержки реально мешает (живой дебаг, дизайн API)
- Полный Opus 4.7 без `/fast` — для критичных задач, где важна точность и время не критично
- Когда нужна максимальная глубина рассуждения — стандартный Opus с `/effort=extra-high`, не `/fast`

КОГДА НЕ БРАТЬ

- **Автономные задачи и долгие рефакторы** — переплачиваешь ×6 за скорость, на которую не смотришь
- **Batch и CI/CD пайплайны** — латентность не критична, стандарт дешевле
- Не лезть выше 300–400К контекста — MRCR падает с 78% (Opus 4.6) до 32% (Opus 4.7)
- Простые задачи без рассуждения — используй Haiku 4.5

ТИПИЧНЫЕ ОШИБКИ

- **Включить `/fast` mid-conversation** — pricing flat, и ×6 цена применяется ко ВСЕМУ предыдущему контексту задним числом, а не только к новым токенам
- **Не замечать косвенной деградации** — на `/fast` токены сжигаются ×6 быстрее, rate-limit упирается раньше, сессия глохнет, не успев довести задачу. Формально качество то же, по факту — короче
- Полагаться на 1М контекст без ручного `/compact` — пропустишь момент, модель уже не вытянет
- Запускать долгие сессии без срабатывания `/compact` заранее — деградация накапливается

ПАМЯТКА ПРО /FAST — ПЕРЕСМОТРЕЛ ПОЗИЦИЮ

Сначала `/fast` казалась прорывом. Бенчмарки одинаковые (SWE-bench Verified 87.6% и там, и там), модель та же — Anthropic честно говорят.

Но ×6 цена + flat pricing при переключении mid-conversation + быстрое исчерпание rate-limit'ов = по ощущениям **дороже и хуже одновременно**. Беру только когда реально сижу за компьютером и каждая секунда задержки бесит. Для автономных задач — стандартный Opus.

ПАМЯТКА ПРО КОНТЕКСТ

0–200К

Можно гонять как есть

200–400К

Пора задумываться о
`/compact`

400К+

Модель галлюцинирует,
переключайся

Карточка 5 · Agent Teams

5 ФЕВРАЛЯ 2026 · EXPERIMENTAL

Экспериментальная фича, активируется через

`CLAUDE_CODE_EXPERIMENTAL_AGENT_TEAMS=1`. Это **не просто параллельные subagents**

(они существуют год). Это новый уровень оркестрации: Team Lead + Teammates, peer-to-peer mailbox-общение, shared task list с автоматическим управлением зависимостями. Стоит **×3-7** от обычной сессии.

КОГДА БРАТЬ

- Задача масштаба «компилятор на 100К строк» или массивный multi-language refactoring
- Когда нужна координация между frontend / backend / tests с peer-to-peer обменом
- Параллельные code review, где reviewers сравнивают findings
- Эксперимент с координацией — если подписка всегда покрывает работу с запасом и rate-limit ни разу не упирался в потолок

КОГДА НЕ БРАТЬ (БОЛЬШИНСТВО ЗАДАЧ)

- **Типовая разработка** — одно `/effort=extra-high` часто работает лучше, чем три teammates со своими контекстами
- Простая декомпозиция на независимые задачи — обычные параллельные subagents проще и дешевле
- **Production-workflow** — experimental-флаг не для боевого использования
- Обычная Pro/Max-подписка — Agent Teams выжигают rate-limit за минуты, после пары сессий придётся ждать сброса окна

ТИПИЧНЫЕ ОШИБКИ

- Спавнить 5+ teammates на задачу, которая решается одним Opus с `/effort=extra-high`
- Использовать на production-проекте — experimental-API может ломаться между релизами
- Не следить за расходом токенов — Agent Teams выжигают rate-limit за минуты

КОНТР-ТЕЗИС ИЗ МОЕЙ ПРАКТИКИ

Дважды пробовал Agent Teams, оба раза вернулся к одному Opus 4.7 на `/effort=extra-high`. На повседневной разработке одна сильная модель с глубоким рассуждением часто даёт более целостный ответ, чем три скоординированных teammates, каждый из которых думал в своём контексте. И в 3-7 раз дешевле.

Карточка 6 · МСП-серверы

ОТКРЫТЫЙ СТАНДАРТ

Model Context Protocol — открытый стандарт, расширяющий Claude Code внешними инструментами. К маю 2026 экосистема резко окрепла.

МИНИМАЛЬНЫЙ НАБОР ДЛЯ ПРАКТИКА

- `context7` — свежая документация по любой библиотеке. Конец устаревшим ответам
- `playwright` — запуск браузера, скриншоты страниц для UI-задач
- `shadcn` — каталог компонентов с поиском и быстрой установкой
- `sequential-thinking` — структурированное многошаговое рассуждение

КОГДА ПОДКЛЮЧАТЬ В ПРОДАКШЕН

- Минимум неделя гоняешь на личных задачах
- Проверил, что не крашит сессию на пограничных сценариях
- Понимаешь, какие действия он может выполнить — у МСП-сервера могут быть widely разные права

КОГДА НЕ ПОДКЛЮЧАТЬ

- Community-проект без активности в репозитории больше 2–3 месяцев
- Сервер просит избыточных прав без обоснования
- Дублирует функциональность встроенного инструмента

ТИПИЧНЫЕ ОШИБКИ

- Подключить 10 серверов сразу — конфликт инструментов, Claude путается
- Не настроить allowedPrompts — каждое действие требует подтверждения, замедляет работу
- Доверять community-серверам без верификации источника

Комбо-приёмы, которые работают

КОМБО · 1 Subagents + Skills

Один Explore-агент находит файлы → возвращает список. Skill `write-pr-description` принимает список → генерирует описание PR. Каждый занимается своим, контексты не пересекаются.

КОМБО · 2 Skills + MCP

Skill `migrate-from-supabase-v3-to-v4` внутри вызывает MCP `context7` для свежей документации Supabase Auth v4 → не путается в устаревшем API.

КОМБО · 3 Cowork + Claude for Small Business

Skill `monthly-financial-report` → Cowork тянет данные из QuickBooks и Stripe через connectors → собирает отчёт. Раньше — час бухгалтера. Сейчас — десять минут.

КОМБО · 4 Opus 4.7 + /fast + ручной /compact

Длинная агентская сессия → каждые 150К токенов вручную вызываем `/compact` с понятными `instructions` → продолжаем работать без деградации. Не ждём, пока модель сама начнёт переспрашивать.

Что НЕ комбинировать

- **Hooks + длинные сессии в worktree** — поведение хрупкое, hook может не сработать. Лучше явные команды в начале промта.
- **Memory system + короткие задачи** — накладные расходы на ведение памяти не оправдывают пользу. Memory — для долгих проектов с регулярными возвратами.
- **Plan mode + simple задача** — overhead больше пользы. Plan mode — для среднесложных задач с реальной декомпозицией.
- **1M контекст + Opus 4.7** — даже Anthropic в system card рекомендуют 4.6 как fallback для long-context retrieval. Используй 4.7 только до ~300K.
- **Agent Teams + ограниченный budget** — выжжешь rate-limit за минуты. Бери только если задача масштаба компилятора и токены не считаешь.

Памятка про мартовский bug

Анти-новинка квартала: v2.1.88 (31 марта 2026)

31 марта Anthropic выкатили версию Claude Code v2.1.88, и в тот же день народ начал жаловаться: токены сжигались в **4-10 раз быстрее обычного** на тех же задачах. На GitHub-issue #42272 — «66% бюджета за 2 вопроса». Десятки идентичных кейсов. Anthropic в тот же день признали проблему и начали фиксить.

В корне была регрессия в обработке plugin overhead и context accumulation — длинные сессии пересчитывали предыдущий контекст квадратично. К середине апреля выкатили фиксы, удвоили 5-часовые rate-limit'ы для Pro и Max, плюс рекомендовали `DISABLE_NON_ESSENTIAL_MODEL_CALLS=1` для тех, кто хочет приструнить background-расход.

Урок: на активной разработке держать одну версию Claude Code больше недели — опасно. Правило: до пятницы — авто-обновление, по пятницам — заморозка. Если выкатят что-то странное, никто не сгорит в выходной.

Обновления и контакты

Эта матрица — срез на май 2026. Anthropic релизит быстро, и через квартал какие-то рекомендации поменяются. Обновлённую версию буду выкладывать в Telegram-канале — там же выкладываю инструменты, к которым прихожу в работе.

Полная статья с разбором каждой фичи, личными кейсами и виральной историей про парня, который через Claude нашёл пароль от Bitcoin-кошелька на \$400 000, — на Хабр, ищется по заголовку «Если пропустили Claude последние 3 месяца».

КАНАЛ

t.me/maslennikovigor

ПРЯМОЙ КОНТАКТ

@maslennikovig

GITHUB (MIT)

github.com/maslennikov-igor/claude-code-orchestrator-kit